

---

# Documentation de la maintenance prédictive

---

## Prédiction des Pannes dans le Système Nheolight Hybrid

Pour prédire les pannes dans le système Nheolight Hybrid, nous avons effectué une analyse détaillée de chaque composant et de ses caractéristiques. L'objectif est de prévoir les défaillances avant qu'elles ne se produisent, afin d'assurer une maintenance préventive et améliorer la fiabilité du système. Ce processus repose sur l'analyse des comportements des composants comme les panneaux solaires, les éoliennes, les batteries et les LED.

### 1. Panneaux Solaires :

Le panneau solaire génère de l'énergie en fonction de l'irradiance solaire et de la température ambiante. Pour calculer l'énergie produite, nous utilisons la relation suivante :

$$P_{\text{solaire}} = P_{\text{nominale}} \times \frac{\text{Irradiance totale}}{1000} \times (1 + \text{Coefficient de Température} \times (T_{\text{réelle}} - 25))$$

Avec :

Puissance nominale : 300 Wp (watt-crête). Cela signifie que sous des conditions idéales, le panneau produit 300 W.

- Température de fonctionnement nominale des cellules (NOCT) :  $45^{\circ}\text{C} \pm 2^{\circ}\text{C}$ , ce qui permet de tenir compte de l'effet de la température sur la performance du panneau.
- Coefficient de température :  $-0.340\ \%/^{\circ}\text{C}$ , indiquant que la puissance du panneau diminue de 0.34 % pour chaque degré au-dessus de  $25^{\circ}\text{C}$ .

### 2. Production de l'Éolienne :

La production de l'éolienne dépend de la vitesse du vent et de la surface balayée par les pales.

La relation pour calculer la production attendue de l'éolienne est :

$$P_{\text{éolienne}} = 0.5 \times \rho \times A \times V^3 \times C_p$$

- $\rho$  : Densité de l'air (environ 1.225 kg/m<sup>3</sup>).
  - $A$  : Surface balayée par les pales, calculée à partir du diamètre des pales.
  - $V$  : Vitesse du vent (en m/s).
  - $C_p$  : Coefficient de performance (environ 0.35 à 0.45).
- La puissance nominale de l'éolienne est 300 W à 12 m/s et peut atteindre 400 W à 20 m/s. Cette relation nous aide à prédire les pannes en comparant la production réelle de l'éolienne avec celle attendue.

### 3. Batterie (Technologie LiFePO4) :

Pour détecter des anomalies et prévoir des pannes, nous surveillons les paramètres suivants :

- Tension : Une batterie LiFePO4 fonctionne typiquement dans une plage de 3.2 à 3.3 V par cellule.
  - Pour une batterie de 24 V avec une capacité de 40 Ah, la batterie contient environ 8 cellules en série. Une tension inférieure à 21.6 V pourrait indiquer une panne imminente.
- Courant de décharge : Si le courant de décharge dépasse la capacité nominale (par exemple, 40 A), cela peut entraîner une surchauffe et endommager la batterie.

### 4. Consommation des LEDs :

Pour détecter des anomalies, nous surveillons les paramètres suivants :

- Courant de fonctionnement nominal : Les LEDs fonctionnent typiquement à 700 mA (à 24 V).
  - Si le courant de décharge dépasse 900 mA, cela peut indiquer une surcharge

Ou un problème avec le driver.
- Protection contre les surtensions : Le driver est protégé contre les surtensions jusqu'à 10 kV. Cependant, une surtension excessive pourrait endommager la lampe LED.

## 5. Modèle de Prédiction des Pannes Utilisé

Pour prédire les pannes dans le système Nheolight Hybrid, nous avons adopté une approche en deux étapes : la détection d'anomalies et la prédiction supervisée.

### *1. Détection des anomalies avec Isolation Forest*

Cette étape vise à identifier les comportements anormaux dans les données provenant des différents composants du système, notamment les panneaux solaires, les éoliennes, les batteries et les LEDs.

Le modèle Isolation Forest, un algorithme non supervisé, est utilisé pour détecter ces anomalies sans nécessiter de données étiquetées de pannes. Il excelle à repérer les comportements inhabituels dans de grands ensembles de données complexes. Dans notre cas, cela inclut des écarts significatifs entre la production attendue et la production réelle des panneaux solaires.

Voici les étapes principales :

- Production attendue : Calculée en fonction des données météorologiques (irradiance, température, heures d'ensoleillement) et des paramètres du panneau solaire.
- Écart relatif : Un seuil est appliqué pour marquer les données comme normales ou anormales.
- Isolation Forest : L'algorithme analyse les tendances des anomalies sur plusieurs jours pour identifier les points critiques.

### *2. Prédiction supervisée avec XGBoost*

Une fois les anomalies détectées, elles servent d'entrée pour un modèle supervisé (XGBoost) chargé de prédire les pannes potentielles dans les trois jours suivants. Ce modèle utilise plusieurs caractéristiques, notamment :

- Les anomalies sur les trois jours précédents,
- La moyenne et l'écart-type des productions passées,
- Les conditions météorologiques actuelles (irradiance, température).

L'intégration de données temporelles permet au modèle d'avoir une vision dynamique du comportement du système.

### *3. Logigramme du panneau solaire*

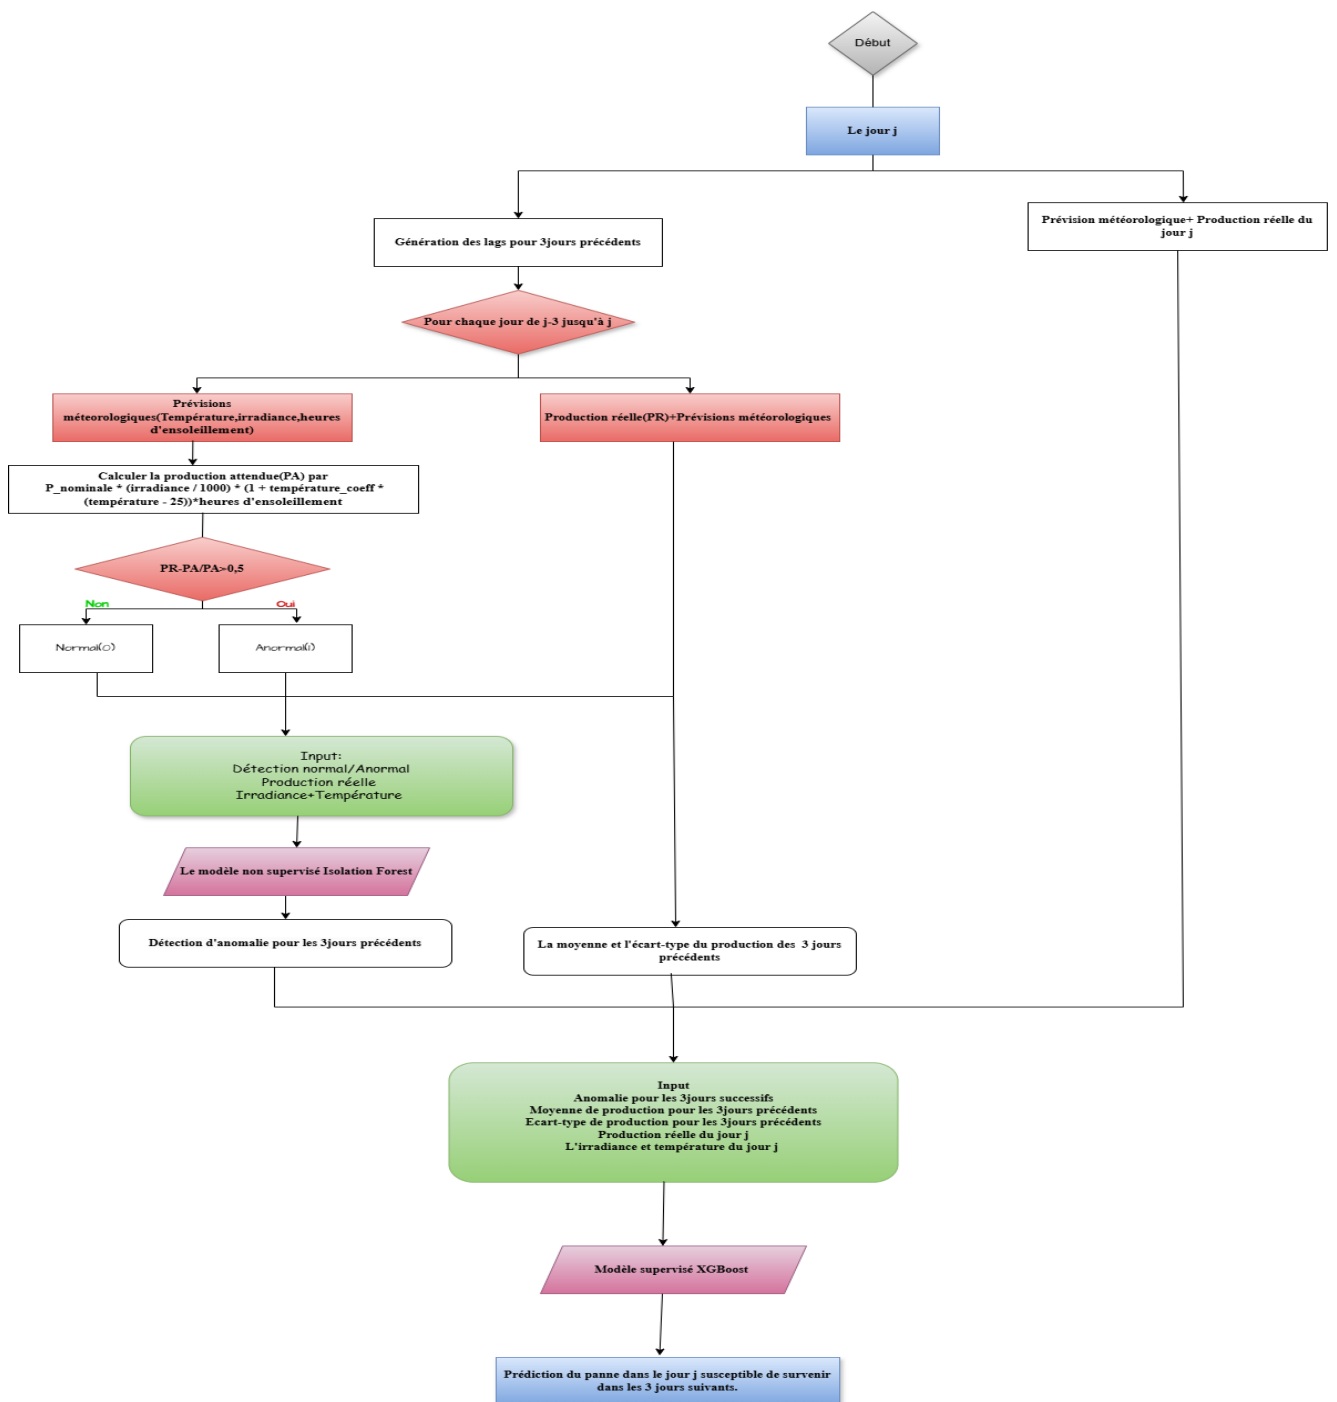
Le logigramme ci-dessous illustre le processus suivi pour prédire les pannes des panneaux solaires dans le système Nheolight Hybrid. Chaque étape a été soigneusement conçue pour analyser les données historiques, détecter les anomalies et anticiper les défaillances potentielles.

Nous commençons par générer des "lags" pour les trois jours précédents, une étape essentielle pour intégrer des données historiques et identifier les tendances passées. Ensuite, nous calculons la production attendue des panneaux solaires en fonction de plusieurs facteurs, notamment la puissance nominale, la température et l'ensoleillement.

Un écart relatif est ensuite déterminé entre la production attendue et la production réelle. Si cet écart dépasse un seuil critique de 50 %, il est marqué comme une anomalie. Ces anomalies sont ensuite analysées à l'aide de l'algorithme Isolation Forest, qui détecte les comportements inhabituels de chaque jour.

Nous intégrons également des statistiques temporelles, comme les moyennes et les écarts-types des trois jours précédents, pour enrichir notre analyse. Enfin, ces informations combinées servent d'entrée à un modèle supervisé XGBoost, qui prédit la probabilité de panne dans les trois jours suivants.


Ce processus rigoureux garantit une détection précise et proactive des pannes, renforçant la fiabilité et la performance du système.



### 3.1. Performance du modèle


Le modèle a atteint une précision de 0,90 pour la classe 0 et de 0,77 pour la classe 1, avec une précision globale de 84 %, démontrant une bonne capacité à détecter les pannes tout en limitant les fausses alertes.

	precision	recall	f1-score	support
0	0.90	0.82	0.86	109
1	0.77	0.87	0.82	78
accuracy			0.84	187
macro avg	0.84	0.84	0.84	187
weighted avg	0.85	0.84	0.84	187



### 3.2. Résultats du modèle

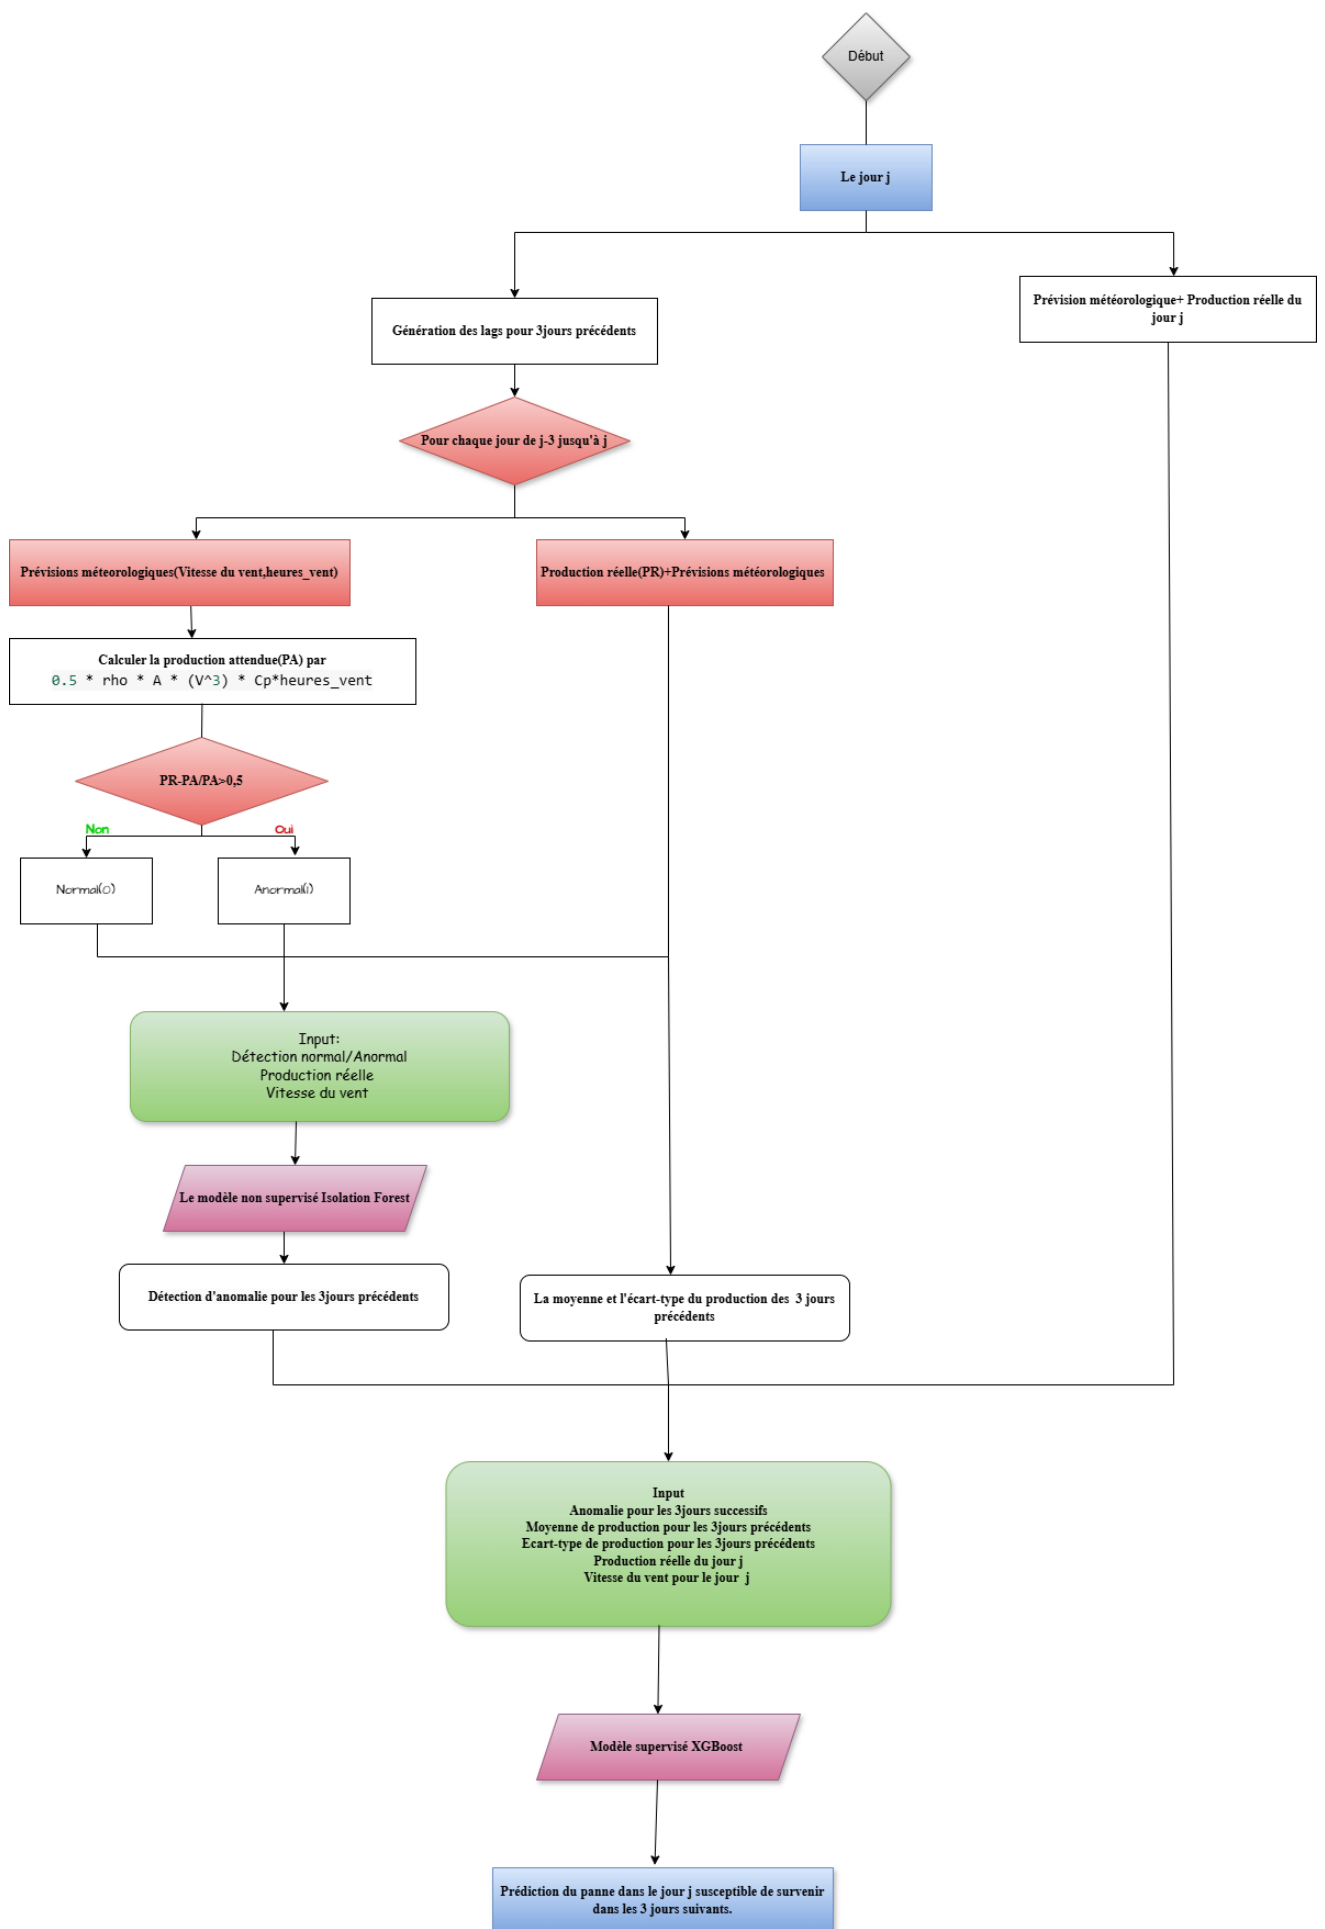
Sur cette courbe, nous illustrons les résultats obtenus en appliquant notre modèle sur des données fictives. Par exemple, la première panne prédite, détectée au 4<sup>e</sup> jour, correspond à une anomalie significative observée dans les 3 jours précédents : un écart notable entre la production réelle (représentée par la courbe bleue) et la production attendue (courbe orange). Cette divergence met en évidence la capacité du modèle à identifier les anomalies et à prédire les pannes de manière fiable, renforçant ainsi sa pertinence pour une application pratique



#### 4. Logigramme de l'éolien

Le logigramme ci-dessous suit La meme logique appliquer au panneau solaire sauf que le calcul de la production attendue et les prévisions météorologiques qui se diffère où ici nous utilisons la vitesse du vent avec les heures du vent






#### 4.1. Performance du modèle

Le modèle a atteint une précision de 0,73 pour la classe 0 et de 0,65 pour la classe 1, avec une précision globale de 96 %, démontrant une bonne capacité à détecter les pannes tout en limitant les fausses alertes.

	precision	recall	f1-score	support
0	0.73	0.64	0.68	25
1	0.65	0.74	0.69	23
accuracy			0.69	48
macro avg	0.69	0.69	0.69	48
weighted avg	0.69	0.69	0.69	48



#### 5. Logigramme de la batterie

Le processus de maintenance prédictive représenté dans le logigramme ci-dessous pour les batteries dans le système Nheolight Hybrid repose sur une méthodologie rigoureuse qui combine l'analyse des données historiques, la détection des anomalies et la prédiction proactive des défaillances potentielles. Tout commence par la génération des "lags" pour les trois jours précédents, une étape

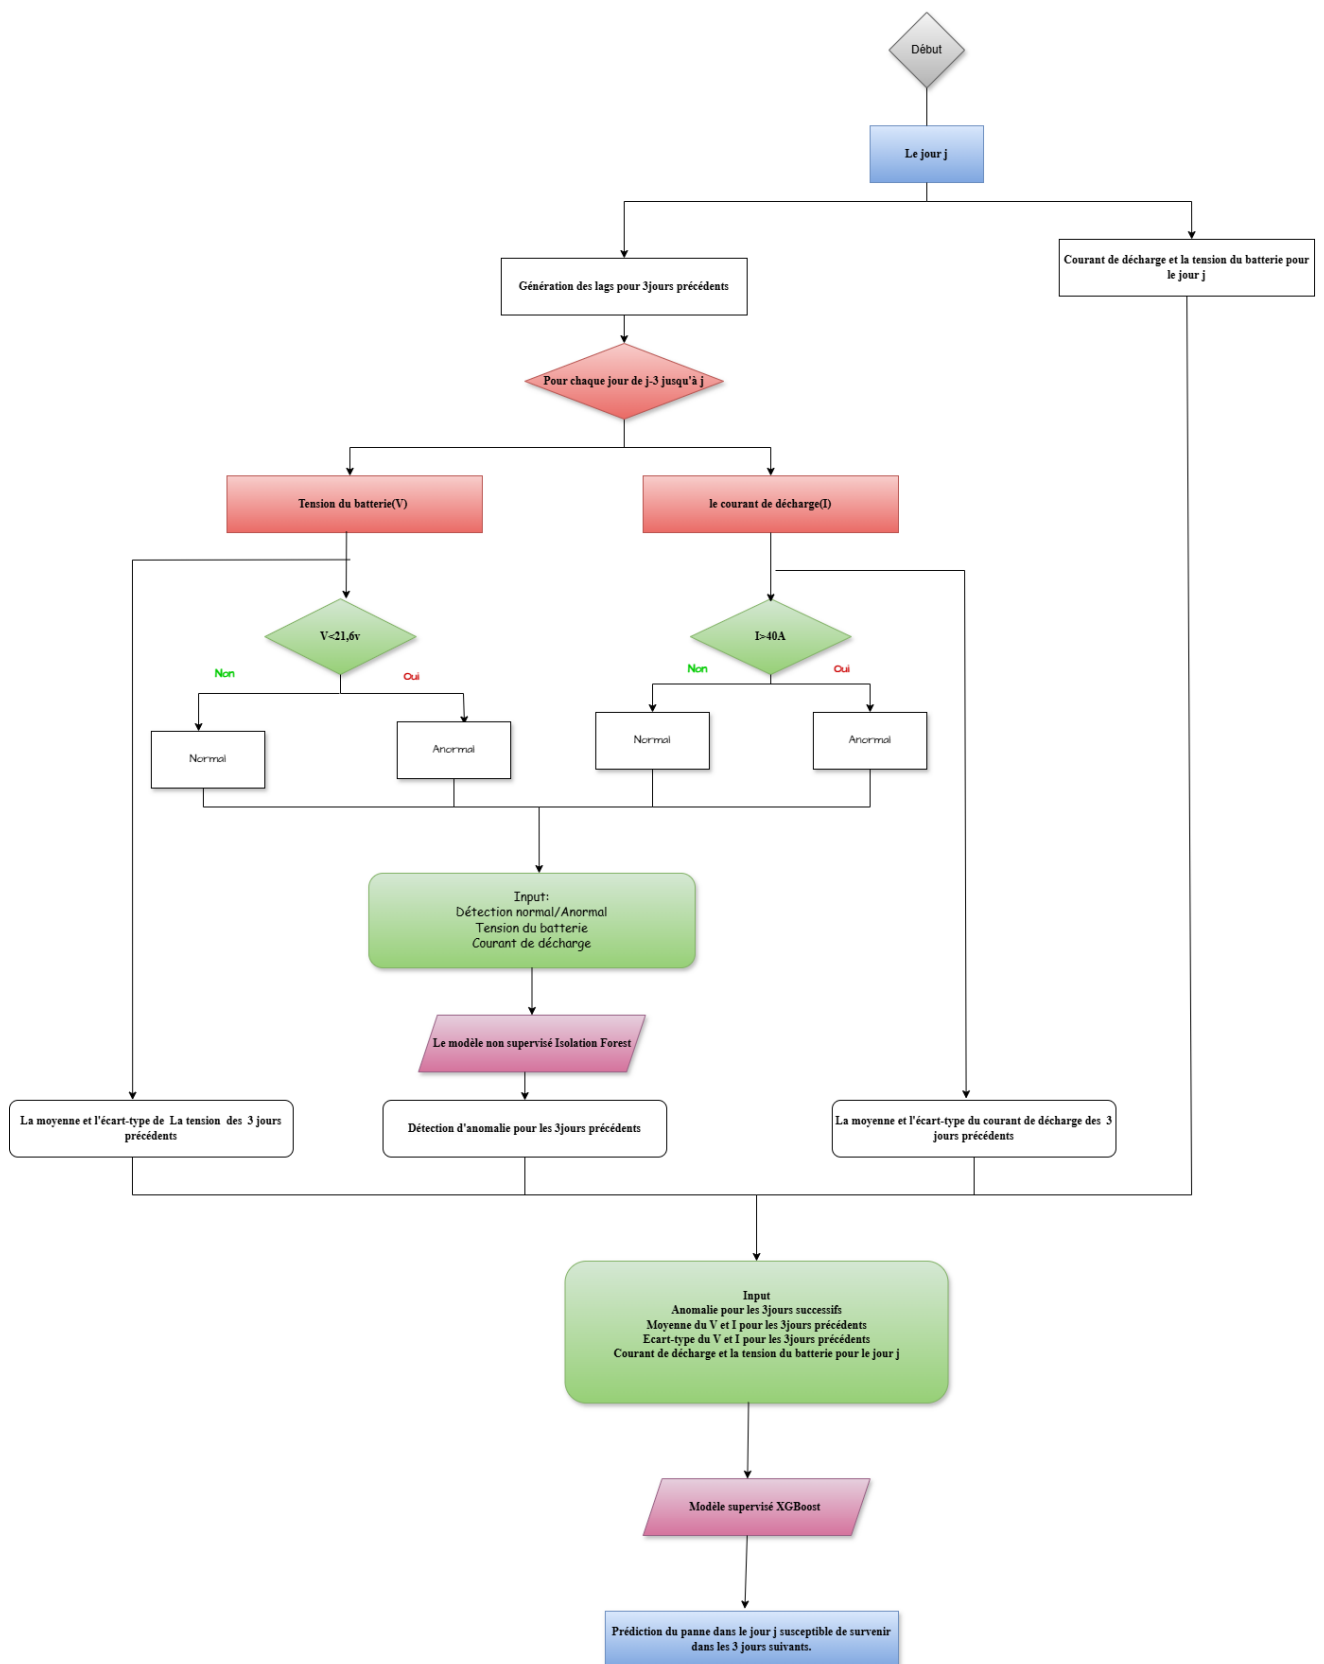
essentielle pour intégrer des informations temporelles relatives à la tension de la batterie et au courant de décharge.

Chaque jour est ensuite analysé individuellement en se basant sur deux seuils critiques : une tension inférieure à 21,6V et un courant de décharge supérieur à 40A. Si l'un de ces seuils est dépassé, une anomalie est identifiée. Ces anomalies initiales sont approfondies à l'aide de l'algorithme non supervisé Isolation Forest, qui permet de détecter des comportements anormaux des batteries sur plusieurs jours consécutifs.

Pour enrichir cette analyse, des statistiques temporelles, comme la moyenne et l'écart-type des valeurs de tension et de courant des trois jours précédents, sont calculées. Ces indicateurs offrent un contexte précieux pour comprendre les variations et tendances des performances des batteries.

Toutes ces informations sont ensuite combinées et utilisées comme entrée pour un modèle supervisé XGBoost. Ce modèle, capable de saisir les relations complexes entre les différentes caractéristiques, prédit la probabilité qu'une panne survienne dans les trois jours suivants.


Cette démarche permet d'anticiper les défaillances potentielles et de prendre des mesures correctives avant qu'elles ne se produisent, réduisant ainsi les temps d'arrêt et les coûts de maintenance. En suivant ce processus méthodique, la fiabilité des batteries est renforcée, et la performance globale du système Nheolight Hybrid est optimisée.



## 5.1. Performance du modèle

Le modèle a atteint une précision de 0,96 pour la classe 0 et de 0,86 pour la classe 1, avec une précision globale de 92 %, démontrant une bonne capacité à détecter les pannes tout en limitant les fausses alertes.

	precision	recall	f1-score	support
0	0.96	0.89	0.92	105
1	0.88	0.96	0.92	93
accuracy			0.92	198
macro avg	0.92	0.92	0.92	198
weighted avg	0.92	0.92	0.92	198



## 6. Logigramme des LEDs

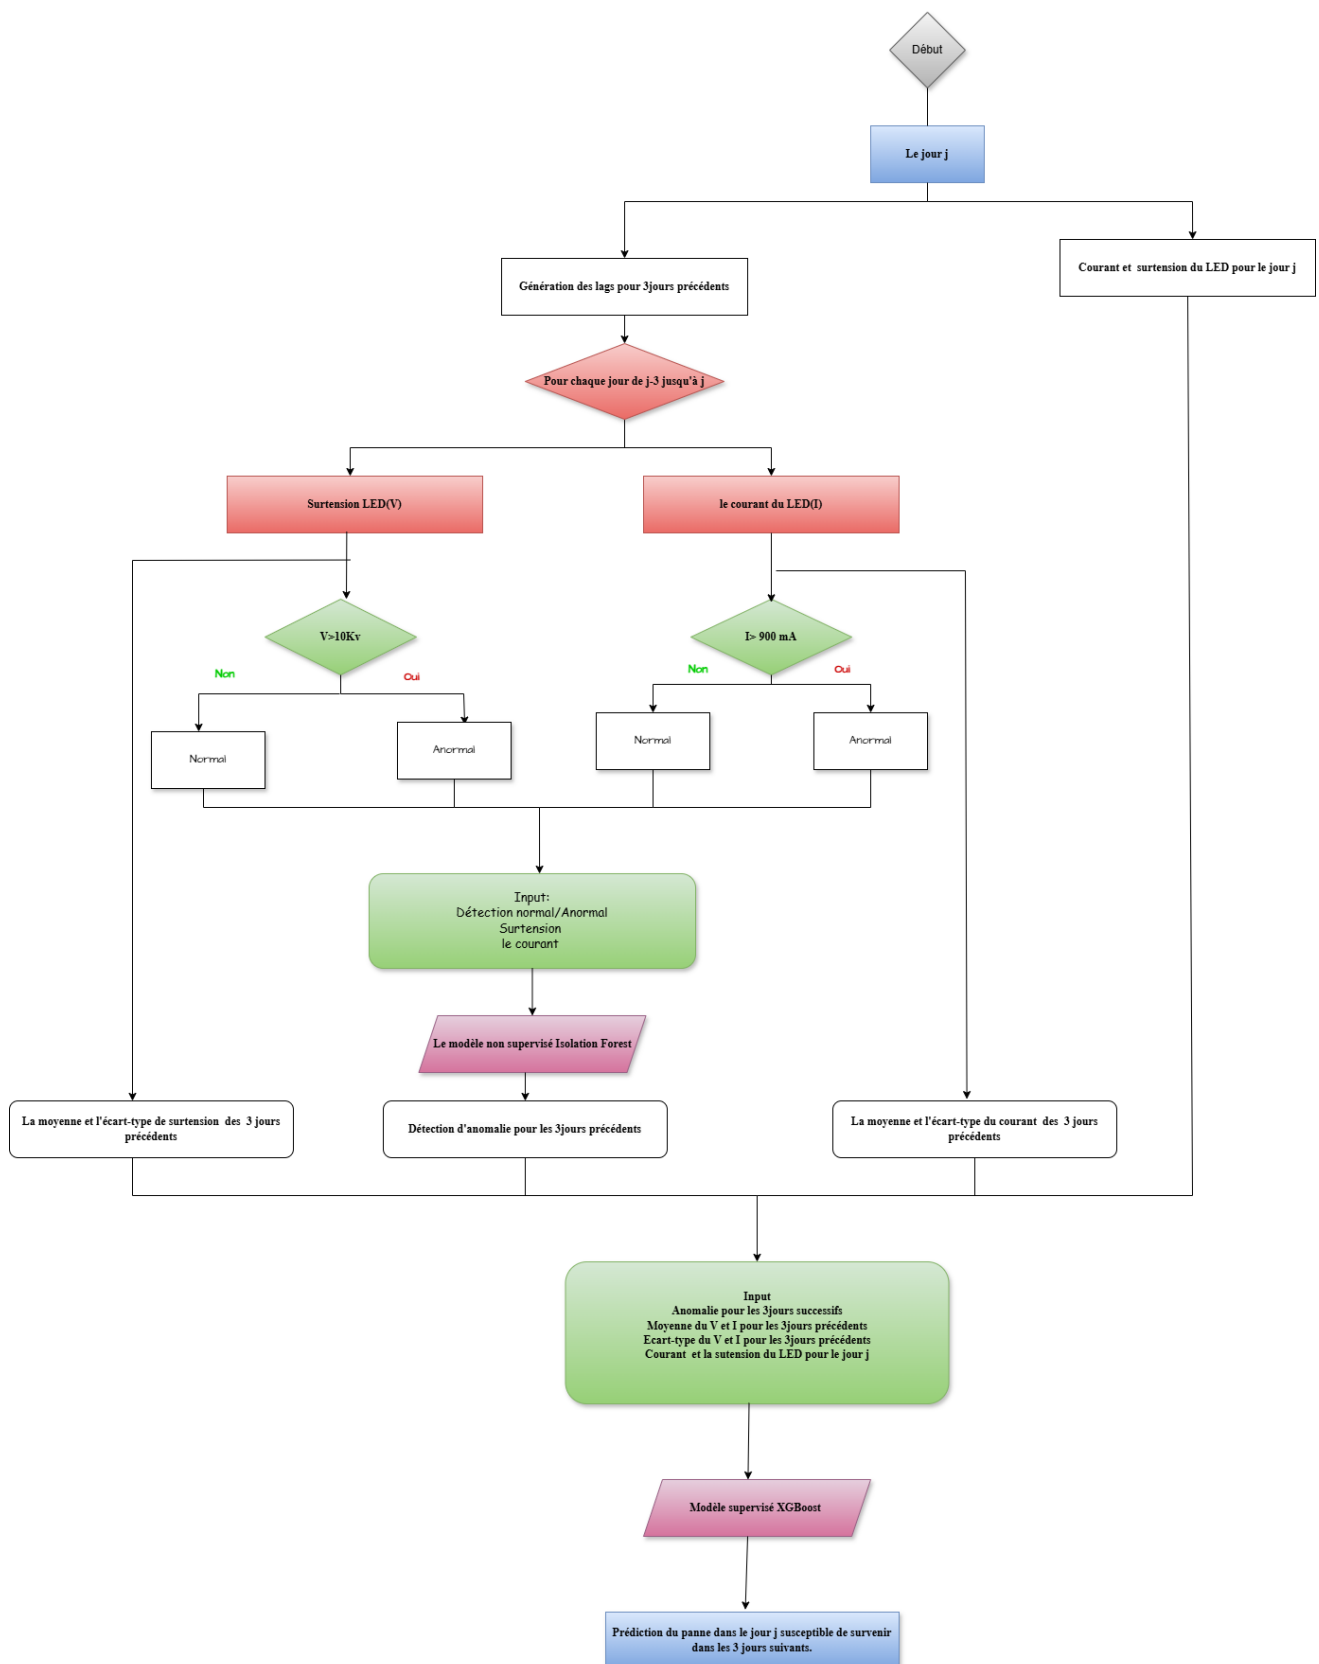
Le processus de maintenance prédictive représenté ci-dessous pour les LED dans le système Nheolight Hybrid suit la même approche méthodique de la batterie afin de détecter les anomalies et prédire les défaillances potentielles. Ce processus commence par la génération des "lags" pour les trois jours précédents, ce qui permet d'intégrer des données historiques sur la surtension et le courant des LED.

Chaque jour est ensuite analysé individuellement en fonction de deux seuils critiques : une surtension supérieure à 10KV et un courant excédant 900 mA. Si l'un de ces seuils est atteint ou dépassé, une anomalie est identifiée. Ces anomalies sont ensuite approfondies à l'aide de l'algorithme non supervisé Isolation Forest, conçu pour détecter des comportements inhabituels sur plusieurs jours consécutifs.

Pour enrichir cette analyse, des statistiques temporelles telles que la moyenne et l'écart-type des surtensions et des courants des trois jours précédents sont calculées. Ces indicateurs permettent de contextualiser les performances des LED dans le temps.

Ces données, combinées avec les informations sur les anomalies, sont ensuite utilisées comme entrées dans un modèle supervisé XGBoost. Ce modèle, qui apprend des relations complexes entre les caractéristiques, prédit la probabilité qu'une panne des LED survienne dans les trois jours suivants.

Ce processus rigoureux offre une prédiction proactive des défaillances, permettant d'anticiper les pannes et de réduire les coûts de maintenance tout en améliorant la fiabilité des LED et la performance globale du système Nheolight Hybrid.



## 6.1. Performance du modèle

Le modèle a atteint une précision de 0,99 pour la classe 0 et de 0,83 pour la classe 1, avec une précision globale de 91 %, démontrant une bonne capacité à détecter les pannes tout en limitant les fausses alertes.

Classification Report - Prédiction à 3 jours pour les LEDs :

	precision	recall	f1-score	support
0	0.99	0.85	0.91	117
1	0.83	0.99	0.91	92
accuracy			0.91	209
macro avg	0.91	0.92	0.91	209
weighted avg	0.92	0.91	0.91	209

